Stemming 是比較簡單的做法,通常稱為 Heuristic process,簡單來說就是制定規則來拆解單詞(rule-based),像是看到 ing/ed 就去除。其中,又以 Porter stemmer 跟 Snowball stemmer 最為常見,前者是運用現有的規則移除常見單詞字尾,後者則是根據使用者對 Porter stemmer 提出的問題加以優化。

Lemmatization 是取出單詞的 Lemma, 且 Lemmatization 需要有字典來尋 找單詞的原型,除此之外 Lemmatization 也可以利用 POS tagging 的訊息來給 出更正確的答案。

大部分的 lemmatization 演算法都是藉由維護大型詞典以及對輸入詞進行 形態分析來達到目標,而 stemming 演算法則由簡單的字串切割、if else 規 則、小型詞典所組成。基本上 Lemmatization 比起 Stemming 會是更好的選 擇,因為它的精度較高,Stemming 唯一的優勢就是速度。